Chapter1 神经元和数学方法

黄志权

2023年5月26日

目录

第一章	IF 模型 (Integrate-and-fire models)										1	
1.1	膜电压 u(t) 演变的线性微分方程推导				•							1
1.2	输入电流为周期性驱动及其傅里叶变换											6

第一章 IF 模型

(Integrate-and-fire models)

神经元的动力模型可以被简化为: 树突接收若干的脉冲信号,并积累到细胞膜上,致使细胞膜电压改变,从而产生动作电位。LF 模型则是将动作电位描述成事件的模型。

1.1 膜电压 u(t) 演变的线性微分方程推导

对于神经元细胞,我们可以将其想象为如下的 RC 电路。细胞膜就像是一个与电阻并联的电容器,而电阻连接着一个电压为 u_{rest} 电池。当没有外界输入时,膜电压 u(t) 为初始值 u_{rest} ; 当有外界脉冲输入时,相当于给电容提供电流为 I(t) 的充电,从而改变模电压 u(t)。//PS: 这个电阻也被称为漏电阻。由于在没有外界输入时,膜上电荷会逐渐穿过细胞膜泄露出去,让膜电压回归 u_{rest} ,因此引入一个漏电阻来模拟这种现象。

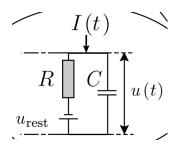


图 1.1: 细胞膜等效电路

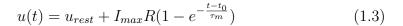
考虑 I(t) 不为零的情况,即有外界输入时,来分析膜电压的变化。首先总电流由并联电路支电流和组成 $I(t) = I_r + I_C$ 。即:

$$I(t) = \frac{u(t) - u_{rest}}{R} + C\frac{du(t)}{dt}$$
(1.1)

模仿电路分析,定义膜时间常数 (membrane time constant) $\tau_m = RC$ 。 从而可以得到 u(t) 的线性微分方程:

$$\tau_m \frac{du(t)}{dt} = -[u(t) - u_{rest}] + RI(t)$$
(1.2)

上式在电路分析中称为 RC 电路响应方程,在神经科学领域称为无源膜方程 (equation of a passive membrane)。这个方程的解分为两个部分。即输入脉冲的充电过程(零状态响应),和没有输入脉冲,电压泄露到 u_{rest} 的过程(零状态响应)。首先是输入脉冲的充电过程(零状态响应),我们假设输入电流脉冲在 t_0 时刻是一个幅值为 I_{max} 的方波,则其方程如下:



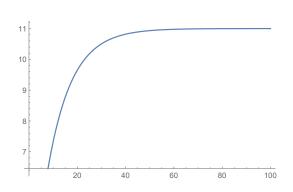


图 1.2: 脉冲充电图

然后是电压泄露到 u_{rest} 的过程(零状态响应),假设脉冲在 t_1 时刻结束:

$$u(t) = u_{rest} + \Delta u R e^{-\frac{t-t_1}{\tau_m}}$$

$$\Delta u = u(0) - u_{rest}$$
(1.4)

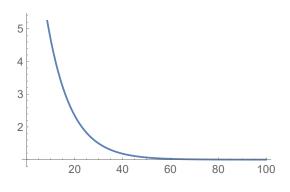


图 1.3: 脉冲放电图

从而,当没有外部脉冲输入的情况下,膜电压会以指数形式衰减到 u_{rest} 。 其衰减时间系数 τm 一般为 10 ms,与一般持续 1 ms 的尖峰脉冲相比长了很多。

我们可以绘制对于方波输入,膜电压的变化图。我一开始打算利用解析解来绘制,但是发现分段条件太难设置了。因此我选择使用微分方程 1.2来模拟,这样子写成递归函数,会非常简便好看。代码和仿真图如下:

```
def U(t_scale, tou, u_t_1, I, R, u_rest):

return (-(u_t_1 - u_rest) + R*I)/tou*t_scale + u_t_1
```

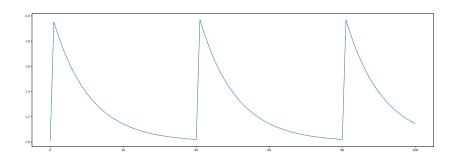


图 1.4: 方波输入响应图

接下来,考虑输入电流 I(t) 为一个持续时间为 Δ 的一个非常短的脉冲。 其膜电压轨迹由 1.3改写得: $u(\Delta) = u_{rest} + I_{max} R(1 - e^{-\frac{\Delta}{\tau}})$ 。对 e 指数函数 做泰勒展开,由于 Δ 已经很小了,因此只需考虑其一阶情况即可:

$$u(\Delta) = u_{rest} + I_{max}R\frac{\Delta}{\tau_m} \qquad for \Delta << \tau_m$$
 (1.5)

然后我们把 Δ 推至无穷小,并 I(t) 变形为一个 δ 函数。从而得到一个 总电量 $q=I_0\Delta$ 不变的脉冲。将 $q=I_0\Delta$ 以及 $\tau_m=RC$ 代入上式可得:

$$u(\Delta) = u_{rest} + \frac{q}{C} \tag{1.6}$$

然后,可以得到输入脉冲结束后电压泄露到 u_{rest} 的过程。将上式带入 1.4,可得:

$$u(t) = u_{rest} + \frac{q}{C}e^{-\frac{t-t_0}{\tau_m}}$$
 (1.7)

从而可以发现,非常窄电流脉冲输入等价于给细胞膜增加了一个 $\frac{q}{C}$ 的电压。当膜电压高于阈值时,会发射一个脉冲,然后膜电压被重置为 u_r ,一定要注意, $u_r!=u_{rest}$,而是比 u_{rest} 要低一些。记在 t^f 时刻发射了脉冲。那么发射脉冲序列可以用狄拉克求和表示:

$$S(t) = \sum \delta(t - t^f) \tag{1.8}$$

前面 1.3和 1.4零状态响应和零输入响应描述的都是 I(t) 为恒定状态的情况。下面考虑 I(t) 为连续的变化信号的情况。由于离散的电流 I 输入实质上是给细胞膜引入一个 $\Delta u = \frac{q}{C} = IR$ 的电压变化,因此连续变化的 I(t) 输入即公式 1.7与 I(t) 的卷积:

$$u(t) = u_{rest} + \frac{q}{C}e^{-\frac{t}{\tau_m}}$$

$$= u_{rest} + IRe^{-\frac{t}{\tau_m}}$$

$$= u_{rest} + RI(t) \bigotimes e^{-\frac{t}{\tau_m}}$$

$$= u_{rest} + R \int_0^{+\infty} I(t-s)e^{-\frac{s}{\tau_m}} d\frac{s}{\tau_m}$$

$$= u_{rest} + \frac{R}{\tau_m} \int_0^{+\infty} I(t-s)e^{-\frac{s}{\tau_m}} ds$$

$$(1.9)$$

上面的式子相当于把输入电流分成无数多小的脉冲,每一个脉冲都会产生 $\Delta ue^{-\frac{t}{rm}}$ 的膜电压变化,然后全部积分起来。那么,同理,我们也可以用同样的方式描述发射脉冲的过程。发射一个脉冲,等价于膜上减少了 $\vartheta-u_r$ 的电压,考虑到发射脉冲是离散的,因此我们可以表示为:

$$\sum_{f} -(\vartheta - u_r)e^{-\frac{t - t^f}{\tau_m}} \tag{1.10}$$

因此, 描述 LF 整个输入-输出的膜电压函数为:

$$u(t) = u_{rest} + \sum_{f} -(\vartheta - u_r)e^{-\frac{t - t^f}{\tau_m}} + \frac{R}{\tau_m} \int_0^{+\infty} I(t - s)e^{-\frac{s}{\tau_m}} ds$$
 (1.11)

1.2 输入电流为周期性驱动及其傅里叶变换

下面我们分析输入电流 I(t) 为周期性函数时,其膜电压响应的形式。我们定义 $\kappa(s) = \frac{1}{c}e^{\frac{s}{\tau_m}}$,则输入电流引起的膜电压的响应可以写作:

$$u(t) = \int_0^{+\infty} I(t-s)\kappa(s)ds \tag{1.12}$$

它具有很漂亮的滤波器的形式,可以看做是滤波器 $\kappa(s)$ 对输入电流 I(t) 卷积。利用傅里叶变换 (Fourier transform) 可以得到其频域响应:

$$u(\omega) = I(\omega)\kappa(\omega) \tag{1.13}$$

现在我们考虑 $I(t) = I_0 e^{i\omega t}$, 代入 1.12可得:

$$u(t) = \int_0^{+\infty} \kappa(s)e^{-i\omega s}dsI_0e^{i\omega t}$$

= $\kappa(\omega)I_0e^{i\omega t}$ (1.14)

考虑 $u(t) = u_0 e^{i(\phi\kappa(\omega) + \omega t)}$, 那么其实部增益就可以写作:

$$\frac{u_0}{I_0} = |\kappa(\omega)| = \int_0^{+\infty} \kappa(s)e^{-i\omega s}ds = \frac{1}{C} \left| \frac{\tau_m}{1 + i\omega \tau_m} \right|$$
 (1.15)

由于 $\omega \tau_m \gg 1$,因此增益约等于 $\frac{1}{C\omega}$ 。因此,其电压增益和输入频率成反比。下面我在 python 中试验一下嘿嘿。利用 Brian2 开源包构建 LIF 模型,频率从 50Hz-500Hz,我们观察其 spike 的次数。可以看到,spike 次数随频率增加有减少的趋势,一定程度上验证了上面的增益公式。

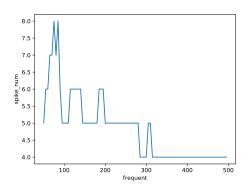


图 1.5: 增益和频率的关系图